Projektarbeit

Certified Artificial Intelligence Engineer

Online News Popularity

verfasst im Rahmen der EN ISO / IEC 17024-Zertifizierungsprüfung von

Jonas Klose

Abgabedatum:01.09.2022

Eidesstattliche Erklärung

Hiermit versichere ich an Eides statt, dass ich die vorliegende Projektarbeit eigenständig und ohne Mitwirkung Dritter angefertigt habe. Quellenangaben wurden entsprechend als solche gekennzeichnet.

Münster, 30.08.2022

Ort, Datum, Unterschrift

Inhalt

1 Einleitung 4
2 Exploration des Datensatzes 5
2.1 Welches sind die 10 populärsten Artikel? 6
2.2 Der Titel 6
2.3 Der Inhalt 8
2.4 Tag der Publikation 8
3 Methode 9
3.1 Preprocessing 9
3.2 Machine Learning Modelle 9
3.3 Ergebnis 10
4 Fazit 10
5 Literaturverzeichnis 11
6 Anhang 11
6.1 Anhang A: 11
6.2 Anhang B 15

1 Einleitung

Online News Artikel sind ein beliebtes Medium, um am Weltgeschehen teilzuhaben und sind im digitalen Zeitalter nicht mehr wegzudenken.
Durch wegfallende Auflagen von Printmedien gewinnt die Monetarisierung dieser zunehmend an Relevanz.
Für Nachrichtenportale ist es deshalb wichtig, einordnen zu können, welche Parameter relevant sind, um Inhalte möglichst attraktiv zu gestalten.

Deshalb wird in diesem Projekt versucht, die Popularität von Online News Artikeln mit Hilfe von Machine Learning Modellen vorherzusagen und Features zu identifizieren, die besonders dazu beitragen.

2 Exploration des Datensatzes

Der Datensatz, der in diesem Projekt verwendet wird, stammt von der amerikanischen Lifestyle-Plattform mashable.com und ist auf der auf UCI Machine Learning Repository[1] zur freien Verfügung gestellt. Die Daten wurden in dem Zeitraum von Januar 2013 bis Januar 2015 erhoben.
Er beinhaltet 39644 Instanzen, welche jeweils einen News-Artikel repräsentieren und 60 Features. Die Targetvariable *„shares“* gibt an, wie oft ein Artikel in Sozialen Medien geteilt wurde.
Neben Rohdaten wie bei den Features *„n_tokens_title,* die Anzahl an Buchstaben in der Überschrift, oder *„num_imgs“*, der Anzahl an Bildern im Artikel, gibt es auch einige vorverarbeitete Features wie bspw. *„average_token_length“* – durchschnittliche Wortlänge oder *„kw_min_min“* - schlechtestes Schlüsselwort (minimum shares).
Zusätzlich wurden Variablen mit Hilfe des *Latent Dirichlet Allocation* Algorhythmus (LDA) aus den Texten der Artikel erstellt, um relevante Themengebiete zu identifizieren und die Nähe der Artikel zu diesen Themengebieten zu bestimmen[2].
Für die komplette Legende der vorhandenen Features siehe Anhang 1.

Mit der describe() Funktion verschaffen wir uns einen ersten Überblick über die Features und deren Ausprägungen.

	n_tokens_title	n_tokens_content	n_unique_tokens	n_non_stop_unique_tokens	num_hrefs	num_self_hrefs	num_imgs	num_videos	average_
count	39644.000	39644.000	39644.000	39644.000	39644.000	39644.000	39644.000	39644.000	396
mean	10.399	546.515	0.548	0.689	10.884	3.294	4.544	1.250	
std	2.114	471.108	3.521	3.265	11.332	3.855	8.309	4.108	
min	2.000	0.000	0.000	0.000	0.000	0.000	0.000	0.000	
25%	9.000	246.000	0.471	0.626	4.000	1.000	1.000	0.000	
50%	10.000	409.000	0.539	0.690	8.000	3.000	1.000	0.000	
75%	12.000	716.000	0.609	0.755	14.000	4.000	4.000	1.000	
max	23.000	8474.000	701.000	650.000	304.000	116.000	128.000	91.000	

	min_negative_polarity	max_negative_polarity	title_subjectivity	title_sentiment_polarity	abs_title_subjectivity	abs_title_sentiment_p
count	39644.000	39644.000	39644.000	39644.000	39644.000	39644.000
mean	-0.522	-0.108	0.282	0.071	0.342	0.156
std	0.290	0.095	0.324	0.265	0.189	0.226
min	-1.000	-1.000	0.000	-1.000	0.000	0.000
25%	-0.700	-0.125	0.000	0.000	0.167	0.000
50%	-0.500	-0.100	0.150	0.000	0.500	0.000
75%	-0.300	-0.050	0.500	0.150	0.500	0.250
max	0.000	0.000	1.000	1.000	0.500	1.000

Der Datensatz ist vollständig und beinhaltet keine fehlenden Werte. Da alle Features numerisch und kategorische Werte wie der Wochentag der Veröffentlichung bereits binär kodiert sind, bedarf es keines weiteren Imputing.

[1] https://archive-beta.ics.uci.edu/ml/datasets/online+news+popularity
[2] Kelwin Fernandes, NESC TEC Porto/Universidade do Porto, Portugal
Pedro Vinagre, and Paulo Cortez, ALGORITMI Research Centre, Universidade do Minho, Portuga

2.1 Welches sind die 10 populärsten Artikel?

Mashable.com ist eine Plattform, die viele Themengebiete miteinander vereint. Dies spiegelt sich auch in den 10 meistgeteilten Artikeln wider. Hier sehen wir Themen aus den Bereichen Tech, Lifestyle, Weltgeschehen und berühmte Persönlichkeiten vertreten

Link	Überschrift	Shares
http://mashable.com/2013/07/03/low-cost-iphone/	Leaked: More Low-Cost iPhone Photos	843300
http://mashable.com/2013/04/15/dove-ad-beauty-sketches/	Dove Experiment Aims to Change the Way You See Yourself	690400
http://mashable.com/2014/04/09/first-100-gilt-soundcloud-stitchfix	'I'm Able to Make My Mark': 10 Employees Describe Startup Life	663600
http://mashable.com/2013/11/18/kanye-west-harvard-lecture/	Kanye West Lectures at Harvard About Creativity	652900
http://mashable.com/2013/03/02/wealth-inequality	Viral Video Shows the Extent of U.S. Wealth Inequality	617900
http://mashable.com/2013/11/12/roomba-880-review/	Roomba 880 Has More Sucking Power, Trouble With Obstacles	441000
http://mashable.com/2014/01/14/australia-heatwave-photos/	It's Hot as Hell in Australia Right Now	310800
http://mashable.com/2013/03/28/blackberry-1-million/	BlackBerry Sold 1 Million BlackBerry 10 Smartphones in Q4	306100
http://mashable.com/2013/11/14/ibm-watson-brief/	IBM Brings Watson to the Masses and Other News You Need to Know	298400
http://mashable.com/2014/10/22/ebola-cdc-active-monitoring	U.S. Will Now Monitor All Travelers From Ebola Zone for 21 Days	284700

2.2 Der Titel

Im nächsten Schritt fangen wir vorne an: Beim Titel.
Der Titel ist das Erste, was Nutzer sehen und kann bereits einen großen Einfluss darauf haben, ob sie weiterlesen möchten. Neben sogenannten „Clickbait“-Titeln, welche die Neugierde des Nutzers wecken sollen, spielt auch die Anzahl der Wörter eine Rolle, wie wir in folgender Grafik sehen können.

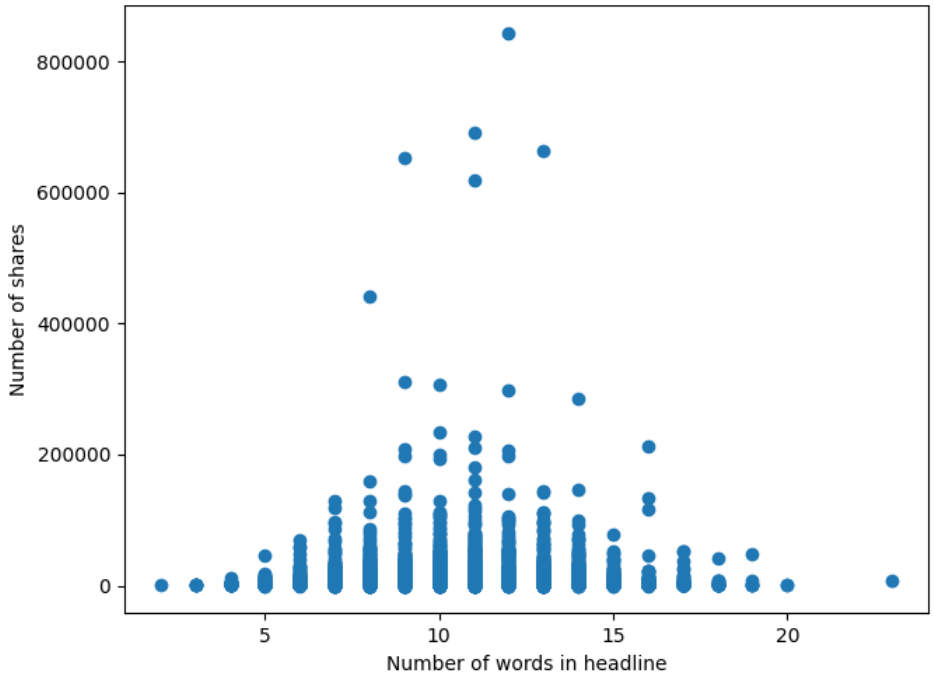

Allerdings ist während des Betrachtens dieser Grafik eine Unregelmäßigkeit aufgetreten. Wenn man sich die Ausreißer ansieht und mit der zuvor aufgeführten Liste der populärsten 10 Artikel vergleicht, sieht man, dass die Ausprägungen der Werte „n_tokens_title“ von der tatsächlichen Anzahl an Wörtern abweichen. Die Ausprägungen dieses Features, welches laut Legende die Anzahl der Wörter im Titel erfassen soll, stimmt in keinem der Fälle mit der tatsächlichen Anzahl an Wörtern in den Überschriften der Artikel überein. Auch durch manuelles Überprüfen der Datensatzreihen darüber und darunter ergibt sich kein schlüssiges Bild.

Da ich bei der Recherche auf einen Artikel[3] gestoßen bin, der ebenfalls die Anzahl an Wörtern im Titeln in Bezug auf Shares geplottet hat und dieselbe Ausprägung auftrat, ist davon auszugehen, dass bei der Kollektion der Daten ein Fehler aufgetreten ist. Da diese fehlerhafte Dokumentation die Ergebnisse verfälschen kann, wurde das Feature „n_tokens_title" entfernt.

[3] Syed Sadiq Ali Naqvi, https://medium.com/@syedsadiqalinaqvi/predicting-popularity-of-online-news-articles-a-data-scientists-report-fac298466e7

2.3 Der Inhalt

Ein weiterer wichtiger Faktor in Bezug auf die Popularität eines Artikels stellt die Anzahl an Wörtern im Artikel dar.

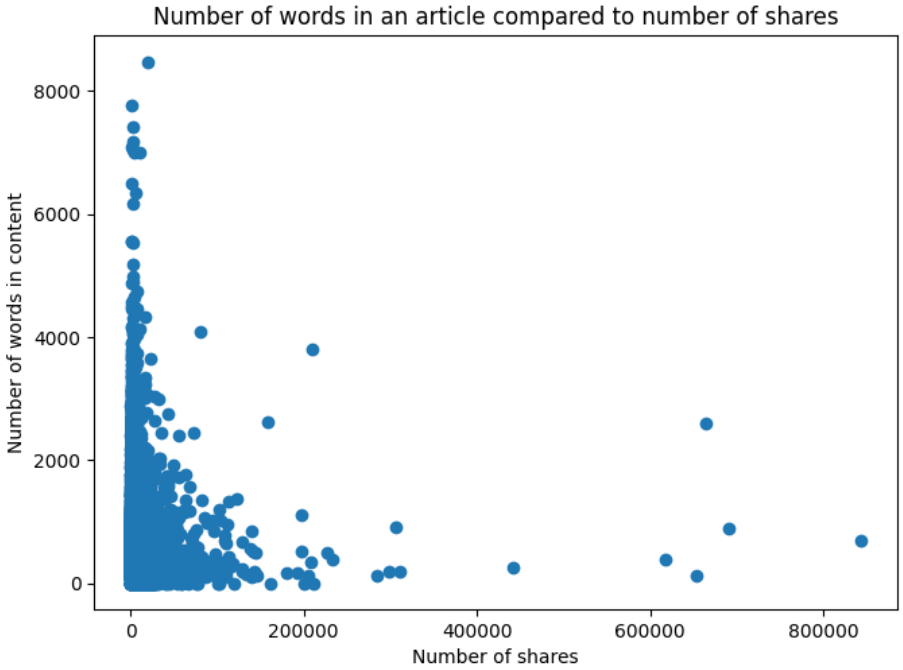

Während Artikel mit sehr vielen Wörtern nur selten geteilt werden, lässt sich erkennen, dass häufig geteilte Artikel tendenziell weniger (<2000) Wörter beinhalten.

2.4 Tag der Publikation

Artikel, die an Wochentagen publiziert worden sind, wurden in der Summe deutlich häufiger geteilt als am Wochenende erschienene Artikel.

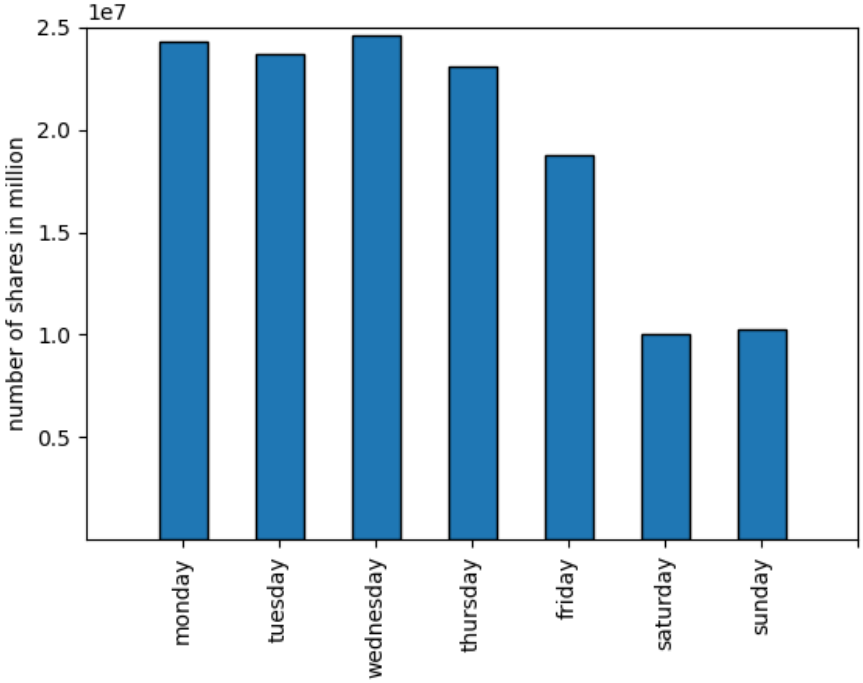

Allerdings wurden an Wochenendtagen deutlich weniger Artikel (durchschnittlich 2595 pro Tag) als an Werktagen (durchschnittlich 6890 pro Tag) publiziert, welche die Diskrepanz in der obigen Grafik erklärt.

3 Methode

Eine Vorhersage darüber zu treffen, wie oft ein Artikel geteilt wird, stellt ein Regressionsproblem dar. Wobei die Daten in Bezug auf die Targetvariable eine hohe Spannweite aufweisen.
Deshalb stelle ich die Hypothese auf, dass eine exakte Vorhersage unmöglich ist. Es kann höchstens eine Annäherung stattfinden, sonst würde es nur noch Artikel geben, die viral gehen. Dies zeigt sich auch in den Ergebnissen der Forscher um Fernandes et al, welche in der Vorhersage der Targetvariable leidiglich eine Akkuranz von 67% erreichen konnten.

Aus diesem Grund habe ich mich dazu entschlossen, die Vorhersage in eine Klassifikationsaufgabe umzuwandeln. Hierfür habe ich mich an den Quartilen der Targetvariable orientiert, wobei das 50% Quartil bei 1400 shares liegt, das 75% Quartil bei 2800 und das arithmetische Mittel bei 3395.

Im Folgenden wurde der Datensatz um eine Spalte ergänzt, welcher die Artikel in populär (1) und unpopulär (0) einteilt. Die Klassifizierung wurde anhand des 75% Quartils vorgenommen, sodass Artikel mit 2800 oder mehr Shares als populär eingestuft wurden. Zwar brachte eine Klassifizierung, welche das arithmetische Mittel als Richtwert nutzte, eine höhere Akkuranz (ca. 5% mit AdaBoost/Randomforest). Allerdings besteht hier eine höhere Gefahr des Overfittings, da die Datenmenge, welche als populär betrachtet wird geringer ausfällt.

3.1 Preprocessing

Wie bereits zuvor erwähnt ist der Datensatz ohne fehlende Werte, sodass sich das Preprocessing auf ein Minimum beschränkt.

Ein paar Features, die keine Relevanz für die Vorhersage hatten, wie die URL des Artikels oder das Feature ‚timedelta', welche die Zeit zwischen Veröffentlich des Artikels und Datenakquisition beschreibt, wurden entfernt.
Um die Rechenoperation zu optimieren, wurde der MinMaxScaler aus der scikit-learn Library verwendet.

3.2 Machine Learning Modelle

Für die Vorhersage bzw. die Kategorisierung in populär/unpopulär wurde der Datensatz mit Hilfe von train_test_split zweigeteilt. Der Trainingsdatensatz umfasst 70% und der Testdatensatz 30% der Instanzen. Im nächsten Schritt wurden die Machine Learning Modelle kNeighborsClassifier,

DecisionTreeClassifier, RandomForestClassifier und AdaBoostClassifier aus der scikit-learn Library mit dem Testdatensatz trainiert.

3.3 Ergebnis

Für die Bewertung der Ergebnisse wurden zwei Messwerte betrachtet. Mittels der .score() Funktion wurde die durschnittliche Akkuranz der Vorhersage gemessen, um festzustellen wie genau die Modelle sind.
Als zweiter Faktor wurde die Zeit gemessen, die für die Berechnung jedes Modells benötigt wurde. Diese kann Aufschluss darüber geben, wie effizient das Modell arbeitet und ggf. eine Entscheidungshilfe sein, welche Modelle sich eignen, um größere Datenmengen zu verarbeiten und gleichzeitig die *Computational Cost* gering zu halten.

```
Model kNN scored with an accuracy of 74.41% in 17.84 seconds
Model Decision Tree scored with an accuracy of 71.99% in 0.67 seconds
Model Random Forest scored with an accuracy of 75.72% in 5.14 seconds
Model Adaboost scored with an accuracy of 75.23% in 3.41 seconds
```

Die besten Vorhersagen mit über 75% Akkuranz lieferten AdaBoost und RandomForest, wobei Adaboost mit 3,41 Sekunden ein Drittel schneller war als der RandomForestClassifier.
Der DecisionTreeClassifier war eindeutig das schnellste Modell mit 0,67 Sekunden, wies aber mit knapp 72% Akkuranz auch die geringste Genauigkeit auf.
Während kNeighborsClassifier (kNN) in der Akkuranz nah an AdaBoost rankommt, ist die verwendete Zeit gegenüber den anderen Modellen mit mit 17,8 Sekunden enorm hoch.

Adaboost scheint somit am besten geeignet, die Popularität von Online News Artikeln zu klassifizieren, da dieses Modell eine im Vergleich hohe Genauigkeit mit geringer Rechenzeit vereint.

4 Fazit

Eine Vorhersage zu treffen, ob und wie populär ein Online News Artikel sein wird ist ein komplexes Unterfangen. Selbst mit modernen Methoden und Machine Learning Modellen kann im Rahmen dieses Projekts nur eine Akkuranz von ca. 75% erreicht werden.

Dies lässt darauf schließen, dass noch mehr Faktoren existieren, die Einfluss auf die Popularität eines Artikels haben können, als dieser Datensatz bereitstellt.

5 Literaturverzeichnis

1. https://archive-beta.ics.uci.edu/ml/datasets/online+news+popularity
2. Kelwin Fernandes, Pedro Vinagre, and Paulo Cortez
   INESC TEC Porto/Universidade do Porto, Portugal, ALGORITMI Research Centre, Universidade do Minho, Portugal, in https://core.ac.uk/download/pdf/55638607.pdf
3. https://medium.com/@syedsadiqalinaqvi/predicting-popularity-of-online-news-articles-a-data-scientists-report-fac298466e7 aufgerufen zuletzt am 30.08.2022

6 Anhang

6.1 Anhang A:

1. Title:

Online News Popularity

2. Source Information

-- Creators: Kelwin Fernandes (kafc '@' inesctec.pt, kelwinfc '@' gmail.com),

Pedro Vinagre (pedro.vinagre.sousa '@' gmail.com) and

Pedro Sernadela

-- Donor: Kelwin Fernandes (kafc '@' inesctec.pt, kelwinfc '@' gmail.com)

-- Date: May, 2015

3. Past Usage:

1. K. Fernandes, P. Vinagre and P. Cortez. A Proactive Intelligent Decision

Support System for Predicting the Popularity of Online News. Proceedings

of the 17th EPIA 2015 - Portuguese Conference on Artificial Intelligence,

September, Coimbra, Portugal.

-- Results:

-- Binary classification as popular vs unpopular using a decision

threshold of 1400 social interactions.

-- Experiments with different models: Random Forest (best model),

Adaboost, SVM, KNN and Naïve Bayes.

-- Recorded 67% of accuracy and 0.73 of AUC.

- Predicted attribute: online news popularity (boolean)

4. Relevant Information:

-- The articles were published by Mashable (www.mashable.com) and their

content as the rights to reproduce it belongs to them. Hence, this

dataset does not share the original content but some statistics

associated with it. The original content be publicly accessed and retrieved using the provided urls.

-- Acquisition date: January 8, 2015

-- The estimated relative performance values were estimated by the authors using a Random Forest classifier and a rolling windows as assessment method. See their article for more details on how the relative performance values were set.

5. Number of Instances:
39797

6. Number of Attributes:

61 (58 predictive attributes, 2 non-predictive,

1 goal field)

7. Attribute Information:

0. url: URL of the article

1. timedelta: Days between the article publication and the dataset acquisition

2. n_tokens_title: Number of words in the title

3. n_tokens_content: Number of words in the content

4. n_unique_tokens: Rate of unique words in the content

5. n_non_stop_words: Rate of non-stop words in the content

6. n_non_stop_unique_tokens: Rate of unique non-stop words in the content

7. num_hrefs: Number of links

8. num_self_hrefs: Number of links to other articles published by Mashable

9. num_imgs: Number of images

10. num_videos: Number of videos

11. average_token_length: Average length of the words in the content

12. num_keywords: Number of keywords in the metadata

13. data_channel_is_lifestyle: Is data channel 'Lifestyle'?

14. data_channel_is_entertainment: Is data channel 'Entertainment'?

15. data_channel_is_bus: Is data channel 'Business'?

16. data_channel_is_socmed: Is data channel 'Social Media'?

17. data_channel_is_tech: Is data channel 'Tech'?

18. data_channel_is_world: Is data channel 'World'?

19. kw_min_min: Worst keyword (min. shares)

20. kw_max_min: Worst keyword (max. shares)

21. kw_avg_min: Worst keyword (avg. shares)

22. kw_min_max: Best keyword (min. shares)

23. kw_max_max: Best keyword (max. shares)

24. kw_avg_max: Best keyword (avg. shares)

25. kw_min_avg: Avg. keyword (min. shares)

26. kw_max_avg: Avg. keyword (max. shares)

27. kw_avg_avg: Avg. keyword (avg. shares)

28. self_reference_min_shares: Min. shares of referenced articles in Mashable

29. self_reference_max_shares: Max. shares of referenced articles in Mashable

30. self_reference_avg_sharess: Avg. shares of referenced articles in Mashable

31. weekday_is_monday: Was the article published on a Monday?

32. weekday_is_tuesday: Was the article published on a Tuesday?

33. weekday_is_wednesday: Was the article published on a Wednesday?

34. weekday_is_thursday: Was the article published on a Thursday?

35. weekday_is_friday: Was the article published on a Friday?

36. weekday_is_saturday: Was the article published on a Saturday?

37. weekday_is_sunday: Was the article published on a Sunday?

38. is_weekend: Was the article published on the weekend?

39. LDA_00: Closeness to LDA topic 0

40. LDA_01: Closeness to LDA topic 1

41. LDA_02: Closeness to LDA topic 2

42. LDA_03: Closeness to LDA topic 3

43. LDA_04: Closeness to LDA topic 4

44. global_subjectivity: Text subjectivity

45. global_sentiment_polarity: Text sentiment polarity

46. global_rate_positive_words: Rate of positive words in the content

47. global_rate_negative_words: Rate of negative words in the content

48. rate_positive_words: Rate of positive words among non-neutral tokens

49. rate_negative_words: Rate of negative words among non-neutral tokens

50. avg_positive_polarity: Avg. polarity of positive words

51. min_positive_polarity: Min. polarity of positive words

52. max_positive_polarity: Max. polarity of positive words

53. avg_negative_polarity: Avg. polarity of negative words

54. min_negative_polarity: Min. polarity of negative words

55. max_negative_polarity: Max. polarity of negative words

56. title_subjectivity: Title subjectivity

57. title_sentiment_polarity: Title polarity

58. abs_title_subjectivity: Absolute subjectivity level

59. abs_title_sentiment_polarity: Absolute polarity level

60. shares: Number of shares (target)

8. Missing Attribute Values: None

9. Class Distribution: the class value (shares) is continuously valued. We transformed the task into a binary task using a decision threshold of 1400.

Shares Value Range:	Number of Instances in Range:
< 1400	18490
>= 1400	21154

6.2 Anhang B

Github Repository Link

https://github.com/JonesX23/OnlineNewsPopularity